Linux Assembly Language - Appunti

Edizioni ByteMan

Presentazione

Tutto il materiale qui presentato è frutto di mie personali ricerche. E' possibile, pertanto, che ci siano incompletezze ed errori. In tal caso, contattatemi. All information provided here derived from my own research. So, mistakes and some sort of incompleteness could exist. If you find any, please, contact me.

Non potevo, passando a Linux, abbandonare il mio linguaggio preferito. Pertanto i primi lavori di prova in questo S.O. me li scrivo in ASM. Si tratta di una raccolta di appunti, numerati progressivamente, per il momento senza alcun ordine logico nella sequenza, che è determinata solo da contingenti necessità di studio e lavoro. E' probabile che in un prossimo futuro sarà possibile una migliore consultazione, al momento ci si deve accontentare di un semplice indice progressivo. Gli esempi presentati hanno prevalentemente funzione didattica e non vengono mai resi complicati per non venir meno alla loro finalità. Mi auguro, comunque, che la fatica per la raccolta del materiale e per la riorganizzazione dello stesso possa tornare utile oltre che ai miei studenti a quanti altri volessero consultare questi appunti. Per il momento mi atterrò alle seguenti convenzioni, fissate anche in funzione del software che uso:

Assemblatore: nasm della NetWide

Linker 1: Id

Linker 2: quello incluso in gcc

· Nomi dei file sorgente: con suffisso .asm

· Nomi dei file oggetto: con suffisso .o

· Nomi dei file eseguibili: senza suffisso

Ecco alcune delle motivazioni:

- Come assemblatore ho scelto nasm per continuare ad usare la sintassi Intel, già utilizzata anche con altri sistemi
 operativi.
 - Non ho intenzione, per il momento, di usare la sintassi AT&T, e quindi non considererò esempi da compilare con gas.
- Utilizzerò il linker gcc solo quando sarà necessario usare le funzioni della libreria libc. Il risultato finale sarà un
 po' più lungo in termini di byte, ma la semplicità con cui si importano le funzioni è, per me, didatticamente più
 importante. Da notare, ancora, che gcc utilizza, a sua volta, il linker ld.
- In tutti gli altri casi utilizzerò, invece, il linker Id per ottenere un eseguibile più compatto.

Introduzione ASM Linux

A partire da un file sorgente è necessario eseguire due operazioni per ottenere un file eseguibile: la compilazione e il collegamento (linking). Durante la fase di compilazione viene effettuata l'analisi necessaria per verificare la correttezza del codice e, in caso di esito positivo, si passa alla traduzione del sorgente in linguaggio macchina. Dopo la fase di compilazione è necessaria una fase di collegamento (linking) in cui si vanno a collegare più file compilati ed eventuali librerie statiche e/o dinamiche per ottenere un file eseguibile correttamente caricabile dal sistema operativo. L'intero procedimento si riduce, quindi, ai seguenti 2 passaggi:

```
nasm -f elf -o prova.o prova.asm
gcc -s -o prova prova.o
```

oppure ai seguenti 2:

```
nasm -f elf -o prova.o prova.asm
ld -s -o prova prova.o
```

In tutti e due i casi il parametro -o è seguito dal nome del file di output, il parametro -f elf specifica il formato del file oggetto, il parametro -s ordina di effettuare lo strip delle funzioni inutili dal file binario di uscita.

Per facilitare la compilazione si possono, in alternativa, usare i seguenti script, migliorabili sicuramente, ma è una cosa che farò in un secondo tempo:

```
#!/bin/sh
                  #!/bin/sh
nasm -f elf -o $1.o $1.asm
                  nasm -f elf -o $1.o $1.asm && gcc -s -o $1 $1.o
gcc -s -o $1 $1.0
                  rm $1.o -f
rm $1.0 -f
                  #!/bin/sh
                  #!/bin/sh
nasm -f elf -o $1.o $1.asm
                  nasm -f elf -o $1.o $1.asm && ld -s -o $1 $1.o
ld -s -o $1 $1.0
              oppure
                  rm $1.o -f
                  rm $1.0 -f
```

La compilazione con l'uso di uno degli script si eseguirà quindi con:

```
./al.sh prova
```

Oltre alla compilazione, lo script provvederà a rimuovere il file oggetto, generalmente non utilizzato, con il comando rm.

L'esecuzione del programma, compilato nella propria cartella di lavoro, si eseguirà digitando:

```
./prova
```

Quasi il classico "Hello world"

Il primo esempio leggerà il marchio di fabbrica della CPU e lo visualizzerà sul terminale. Il codice è scritto per macchine di classe Pentium e non esegue alcun controllo per i 486 o precedenti.

```
; hello_1.asm
; compilare con nasm+qcc
global main
extern printf
section .data
cls
     db 1Bh,"[2J",0
     db 0Dh,0Ah, "Marchio del produttore della CPU: "
msa
idx
     dd 0,0,0
     db 0Dh, 0Ah, 0Ah, 0
section .text
    push
                       ;Clear del terminale
main:
           dword cls
     call
           printf
     pop
           eax
     mov
           eax,0
                       ; Identificazione CPU
     cpuid
           [idx],ebx
                      ;Lettura prime 4 lettere
     mov
           [idx+4],edx
                      ;Lettura 4 lettere centrali
     mov
           [idx+8],ecx
                      ;Lettura ultime 4 lettere
     mov
     push
           dword msg
                       ;Output Messaggio
     call
           printf
     pop
           eax
     ret
                       ;Uscita programma
```

L'esempio appena illustrato esegue quattro operazioni: la pulizia del terminale, l'identificazione della CPU, l'emissione di un messaggio, l'uscita dal programma. L'uso della printf, appartenente alla libreria libc, semplifica le operazioni di output su terminale (clear e messaggio), si noti il passaggio del parametro (puntatore alla stringa) tramite una push con conseguente pop per ripristinare lo stato dello stack. Al posto della pop eax, che coinvolge l'uso di un registro, si potrebbe usare una add esp,4 che risolve il problema del riallineamento dello stack senza coinvolgere registri. L'uscita del programma realizzata con una semplicissima ret.

Ci proponiamo di risolvere lo stesso problema con l'uso di chiamate al kernel, ovvero con le cosiddette syscall. La soluzione è leggermente più complessa, ma è di particolare interesse il passaggio dei parametri tramite registri; si noti, in particolare, che il registro eax viene utilizzato per individuare il numero della syscall da usare, mentre i parametri (par1, par2, par3, ...) vengono passati ordinatamente tramite i registri ebx, ecx, edx, esi, edi, ebp, rispettivamente. Il confronto con la soluzione precedente evidenzia alcune cose: l'assenza della dichiarazione extern, la mancanza del terminatore null alla fine delle stringhe, la presenza di una costante per l'individuazione della lunghezza delle stringhe.

```
; hello 2.asm
; compilare con nasm+ld
global main
section .data
     db 1Bh,"[2J"
cls
CLS
          $-cls
     equ
msq
     db 0Dh,0Ah, "Marchio del produttore della CPU: "
     dd 0,0,0
     db 0Dh,0Ah,0Ah
MSG
     equ
           $-msq
section .text
main:
                       ;Clear del terminale
     mov
           edx,CLS
                       ;par3: lunghezza del messaggio
           ecx,cls
                       ;par2: indirizzo del messaggio
     mov
```

```
mov
            ebx,1
                        ;par1: descrittore del file (stdout)
                    numero della syscall write
      mov
            eax,4
      int
            80h
                       ;chiamata kernel syscall
           mov
            eax,0
                        ;Identificazione CPU
      cpuid
      mov
      mov
      mov
      mov
            edx,MSG
                        ;par3: lunghezza del messaggio
            ecx,msg
      mov
                        ;par2: indirizzo del messaggio
            ebx,1
                       ;parl: descrittore del file (stdout)
      mov
                       ;numero della syscall write
            eax,4
      mov
      int
            80h
                       ;chiamata kernel syscall
                       ;Uscita programma
      mov
            ebx,0
                       ;Par1: codice di ritorno
                  numero della syscall exit
            eax,1
      mov
           80h
                        ;chiamata kernel syscall
      int
```

Se effettuiamo un confronto sulla lunghezza dei due eseguibili ottenuti, anche se i sorgenti non sono perfettamente identici, possiamo notare l'evidente maggior compattezza di hello_2 rispetto ad hello_1.

```
-rwxr-xr-x 1 byteman users 2972 nov 1 19:02 hello_1*
-rwxr-xr-x 1 byteman users 576 nov 1 19:04 hello_2*
```

Complementi

Per quanto riguarda l'identificazione della CPU, ecco quale stringa viene restituita a seconda dei principali produttori:

```
AMD "AuthenticAMD"

Centaur "CentaurHauls"

Cyrix "CyrixInstead"

Intel "GenuineIntel"

NexGen "NexGenDriven"

Rise "RiseRiseRise"

UMC "UMC UMC UMC"
```

Input/Output di testo

Nell'esempio seguente vogliamo coinvolgere alcune funzioni base necessarie in quasi tutti i programmi: l'input da tastiera, l'elaborazione, l'output su video e l'output di errori. Prenderemo in considerazione la trasformazione in maiuscolo di una stringa immessa da tastiera. Utilizzeremo solo syscall e pertanto potremo eseguire il link direttamente con ld. Creeremo le condizioni per generare un errore, nel caso di input nullo, in modo da utilizzare tre descrittori di file: STDIN per l'input, STDOUT per l'output normale, STDERR per l'output d'errore.

```
; upper_1.asm
; Converte in maiuscolo l'input dell'utente.
; compilare con nasm+ld
%define STDIN 0
%define STDOUT 1
%define STDERR 2
%define SYSCALL_EXIT 1
%define SYSCALL_READ 3
%define SYSCALL_WRITE 4
%define BUFLEN 256
      section .data
db "Digita una stringa: " ; prompt
; lunghezza di msgl
      section .data
                                  ; Sezione dati inizializzati
msg1:
MSG1:
msg2: db "Originale: "
                                ; lunghezza di msg2
MSG2: equ $-msg2
msq3: db "Convertita: "
MSG3: equ $-msg3
                                 ; lunghezza di msg3
msg4: db 10, "ERRORE: input nullo.", 10 ; messaggio d'errore
MSG4: equ $-msg4
                                 ;lunghezza di msg4
                                  ; Sezione dati non inizializzati
      section .bss
buf: resb BUFLEN
                                 ; buffer di input da tastiera
newstr: resb BUFLEN
                                  ; buffer di output conversione
rlen: resb 4
                                  ; lunghezza stringa in input (incluso l'invio)
                             ; Sezione codice
      section .text
                                 ; let loader see entry point
      global _start
mov eax, SYSCALL_WRITE ; write function
mov ebx, STDOUT ; Arg1: file descriptor
mov ecx, msg1 ; Arg2: addr of message
             edx, MSG1
      mov
                                 ; Arg3: length of message
      int
             080h
                                  ; syscall kernel to write
mov eax, SYSCALL_READ ; read function
mov ebx, STDIN ; Arg 1: file descriptor
mov ecx, buf ; Arg 2: address of buffer
mov edx, BUFLEN ; Arg 3: buffer length
      int
            080h
                                 ; syscall kernel to read
mov [rlen], eax ; salva la lunghezza della stringa
      dec
             eax
                                 ; decrementa per escludere l'invio
      cmp
                                 ; Test su zero
             eax, 0
            read_OK
                                 ; Uscita read_OK se Test>0
      jg
mov eax, SYSCALL_WRITE ; write function
             ebx, STDERR
                                 ; Arg1: file descriptor
      mov
             ecx, msg4
                                 ; Arg2: addr of message
      mov
             edx, MSG4
      mov
                                 ; Arg3: length of message
       int 080h
                                 ; syscall kernel to write
             exit1
                                  ; salta all'uscita: errore =1
       jmp
```

```
mov esi, buf ; puntatore al buffer di input mov edi, newstr ; puntatore al buffer di conversione nextch: mov al, [esi] ; legge un carattere inc esi ; aggiorna il puntatore al, 'a' ; jb store
      cmp al, 'z'
                            ; Se NO: Salta la conversione
      ja
           store
and al,ODFh store: mov [edi], al
                            ; Se SI: Converte in maiuscolo
                            ; memorizza il carattere
      inc edi
                            ; aggiorna il puntatore destinazione
      dec
          ecx
                            ; aggiorna il contatore
      jnz
          nextch
                            ; ricicla
mov eax, SYSCALL_WRITE; write message
      mov
           ebx, STDOUT
           ecx, msg2
      mov
           edx, MSG2
      mov
      int
           080h
mov eax, SYSCALL_WRITE ; write user input
          ebx, STDOUT
      mov ecx, buf mov edx, [rlen]
          080h
      int
mov EAX, SYSCALL_WRITE ; write message
           EBX, STDOUT
      mov
           ECX, msg3
      mov
           EDX, MSG3
      mov
           080h
      int.
mov EAX, SYSCALL_WRITE ; write out string
           EBX, STDOUT
      mov ECX, newstr
      mov EDX, [rlen]
          080h
      int
mov EBX, 0
                    ; exit code, normal=0
           exit
      jmp
          EBX, 1
exit1: mov
                            ; exit code, error=1
          EAX, SYSCALL_EXIT ; exit function
exit: mov
     int 080h
                             ; syscall kernel to take over
```

Tra le cose da notare, l'inserimento della sezione .bss per la definizione di variabili non inizializzate (i buffer: buf e newstr), in contrapposizione alla sezione .data; ed ancora le pseudoistruzioni %define per introdurre delle costanti. Infine la funzione exit riporta in ebx un codice di uscita che vale "0" se tutto si è concluso regolarmente, oppure "1" in caso di uscita su STDERR.

Recuperare la command line, e non solo

Quando un programma elf viene lanciato eredita una serie di informazioni depositate come dword sullo stack. Queste informazioni riguardano sia la command line, completa di tutti gli argomenti, sia le variabili d'ambiente associate. La situazione dello stack, all'inizio dell'esecuzione, è schematizzata nella figura seguente.

argC	integer: Numero di argomenti (C=N+1)				
arg0	pointer: Nome del programma				
arg1	pointers: Argomenti command line				
arg2					
	pointers. Augumenti command line				
argN					
null	integer: Terminatore argomenti				
env0					
env1	pointers: Variabili d'ambiente				
envM					
null	integer: Terminatore variabili				

L'esempio seguente estrae dallo stack tutto il contenuto schematizzato nella tabella precedente e lo visualizza sul terminale. La conversione del contatore è effettuata per semplicità, nell'ipotesi che il suo valore sia minore di 10, aggiungendo semplicemente una costante opportuna.

```
; commline_1.asm
; Visualizza command line e variabili d'ambiente.
; compilare con nasm+ld
%define STDOUT 1
%define SYSCALL_EXIT 1
%define SYSCALL_WRITE 4
global _start
                               ;necessario per il linker ld
      section .data
                               ; Sezione dati inizializzati
            ODh, OAh, "Numero di argomenti:
msq1
argc
      db
            " incluso il nome del programma.", ODh, OAh
MSG1
      equ
            $-msg1
            ODh,OAh, "Elenco argomenti: ",ODh,OAh
msg2
      db
MSG2
            $-msq2
      equ
            ODh,OAh, "Elenco variabili d'ambiente: ",ODh,OAh
msq3
      db
MSG3
            $-msq3
      equ
crlf
            0Dh,0Ah
      db
xflag
      dd
            0
      section .text
_start:
; Estrae il contatore degli argomenti
      pop
            ecx
            ecx,20202030h
                              ; Conversione in ASCII (Ipotesi N<10)
      add
      mov
            [argc],ecx
                              ; Inserimento nel corpo di msgl
            eax, SYSCALL_WRITE
                              ; write function
      mov
                               ; Argl: file descriptor
            ebx, STDOUT
      mov
            ecx, msg1
      mov
            edx, MSG1
      mov
      int
            80h
                               ; syscall kernel to write
eax, SYSCALL_WRITE ; write function
      mov
            ebx, STDOUT
                               ; Arg1: file descriptor
      mov
            ecx, msg2
      mov
            edx, MSG2
      mov
```

```
80h
                            ; syscall kernel to write
utilizzato sia per gli argomenti sia per
                                le variabili d'ambiente
xloop: pop
           ecx
                            ; Estrae un puntatore
     or
           ecx,ecx
                            ; Verifica se null
           exit1
                            ; Se SI: va a exit1
     jz
                            ; Se NO: prosegue
           esi,ecx
                            ; Utilizza Puntatore esi per usare la lodsb
     xor
           edx,edx
                            ; Azzera contatore lunghezza (edx)
     dec
           edx
strlen: inc
                            ; calcola la lunghezza di msg
           edx
     lodsb
     or
           al,al
           strlen
     inz
                            ; Visualizza msg
           eax, SYSCALL_WRITE
     mov
                           ; write function
           ebx, STDOUT
                            ; Arg1: file descriptor
     mov
           80h
     int
                            ; syscall kernel to write
     call
           newln
                            ; Aggiunge un newline
     jmp
          short xloop
                            ; Ricicla
exit1: mov
           eax,[xflag]
     inc
           eax
           [xflag],eax
     mov
     cmp
           eax.2
           exit
     iе
eax, SYSCALL_WRITE ; write function
     mov
           ebx, STDOUT
     mov
                           ; Argl: file descriptor
     mov
           ecx, msg3
           edx, MSG3
     mov
           80h
     int.
                            ; syscall kernel to write
           short xloop
                            ; Rientra Secondo giro
     ami
exit:
           EBX, 0
                            ; exit code, normal=0
           EAX, SYSCALL_EXIT
     mov
                            ; exit function
           80h
                            ; syscall kernel to take over
     int
eax, SYSCALL_WRITE ; write function
newln: mov
           ebx, STDOUT
                            ; Arg1: file descriptor
           ecx, crlf
     mov
     mov
           edx, 2
           80h
                            ; syscall kernel to write
     int
     ret
```

Poichè le variabili d'ambiente sono molte è opportuno avviare il programma con:

```
./commline_1 ... | more
```

in modo da potere scorrere agevolmente tutto l'output. Si noterà, tra l'altro, che l'ultima voce delle variabili d'ambiente contiene ancora il nome del programma, che era già presente come arg0 nella lista degli argomenti.

Talvolta è necessario, invece, avere dei puntatori diretti ad alcuni punti speciali dello stack, senza dovere essere costretti a scaricarlo tutto, ecco alcuni suggerimenti:

```
; Lettura contatore degli argomenti
       pop
                eax
                                        ; Il reg. esi punta il primo degli argomenti
       pop
                esi
oppure
                                        ; Lettura contatore degli argomenti
       qoq
                eax
                                        ; Il reg. esi punta l'ultimo degli argomenti
                esi,[esp+eax*4]
oppure
                eax
                                        ; Lettura contatore degli argomenti
       pop
                esi,[esp+(eax+1)*4]
                                        ; Il reg. esi punta la prima var. d'ambiente
       mov
```

E' evidente che queste istruzioni devono essere usate proprio all'inizio del programma, prima di avere alterato lo stato dello stack.

L'esempio precedente ha, secondo me, l'inconveniente di alterare la situazione dello stack in quanto c'è una palese quantità di istruzioni di pop non equilibrate o da altrettante istruzioni di push o da una opportuna modifica del valore del registro esp. A tal proposito, c'è una scuola di pensiero che vuole che il programmatore, all'uscita del programma, lasci il puntatore di stack con lo stesso valore trovato all'inizio.

Quella che segue è una variante breve dell'esercizio precedente che illustra questo secondo modo di agire, per semplicità tratta soltanto gli argomenti della command line.

```
; commline_2.asm
; Visualizza la command line
; compilare con nasm+qcc
%define STDOUT 1
%define SYSCALL_WRITE 4
     global main
     extern printf
     section .data
               ODh, OAh, "Numero di argomenti: "
     msg1 db
     dd 0
argc
     db
          " incluso il nome del programma. ", ODh, OAh
    db " inclu
equ $-msg1
db '%s', 1
MSG1
          '%s', 10, 0 ; Stringa di formato
format: db
     section .text
main:
xloop: push ecx
push edx
                   ; Salvataggio registri usati da printf
push dword [edx] ; Passa puntatore stringa
push dword format ; Passa stringa formato
call printf ; Visualizza argomento
add esp, 8 ; Rimozione parametri dall
    add esp, 8
                          ; Rimozione parametri dallo stack
pop edx
pop ecx
add edx, 4
dec ecx
                          ; Ripristino registri
                          ; Modifica puntatore ad arg successivo
                          ; Decrementa contatore
     jnz
         xloop
                           ; Ricicla
     ret
```

Abbiamo usato il linker gcc in quanto si è preferito, per semplicità, effettuare l'output tramite la printf; si noti, a questo proposito, l'uso della stringa di formato dentro il segmento .data per concorrere al formato della printf. Il puntatore di stack esp, alla fine del programma, rimane inalterato.

I colori sul terminale e le macro

Gli esercizi di questa sezione hanno un duplice scopo:

- · realizzare l'output su terminale di un testo a colori
- utilizzare le macro in un programma nasm.

Il primo problema lo risolviamo con le sequenze di escape. In sostanza inviando una stringa opportuna al terminale è possibile reimpostare gli attributi colore. Questa stringa, in particolare, che chiameremo foba (foreground background) è composta da 9 byte ed ha la seguente struttura:

1Bh	5Bh	33h		3Bh	34h		6Dh	00h
esc	[3		,	4		m	null
0	1	2	3	4	5	6	7	8

I byte nelle posizioni 3 e 6 rappresentano i colori di foreground e di background rispettivamente, e vanno impostati secondo la seguente tabella:

30h	0	nero
31h	1	rosso
32h	2	verde
33h	3	ocra
34h	4	blu
34h 35h	5	blu fucsia

Ad esempio per impostare i colori rosso/blu (rosso su fondo blu) occorrerà definire una stringa che contenga in posizione 3 il byte 31h ed in posizione 6 il byte 34h, come illustrato di seguito:

```
foba db 1Bh,5Bh,33h,31h,3Bh,34h,6Dh,00h
oppure
foba db 1Bh,"[31;44m",0
```

Tornando al problema del testo colorato sul terminale, una prima soluzione viene proposta nel listato seguente nel quale sono presenti delle macro sviluppate nell'ultimo listato. Per mia convenzione, i nomi delle macro asm iniziano con il carattere @ in modo che sia facile individuarle nel listato del programma. Si noti la presenza della direttiva %include che consente l'aggancio del file con le macro.

```
; txtcol 1.asm
;compilare con nasm+gcc
%include "macrobase.mac"
global main
extern printf
section .data
foba db 1Bh, "[37;40m",0
     db 1Bh,"[2J",1Bh,"[1;1f",0
cls
crlf
     db 0Dh,0Ah,0
msg20 db "Scritta in verde su fondo nero",0
msg02
     db "Scritta in nero su fondo verde",0
     db "Scritta in bianco su fondo rosso",0
msg71
section .text
main:
      @outterm
                               ; Clear del terminale
              cls
      @fixcol
              2,0
                               ; Imposta Verde/Nero
      @outterm
              msg20
                               ; Emette Messaggio
```